

Projekt wbudowanego systemu wizyjnego zwiększającego autonomię wodnych pojazdów elektrycznych

Projekt grupowy laboratorium przedmiotu Wodne Pojazdy Elektryczne

System wizyjny do monitorowania stanu
morza i estymacji parametrów fal

Autorzy:

Mateusz Bruździak, Miłosz Dorsz,

Marek Mikke, Mateusz Wieczorek

1. Wstęp

Niniejszy raport dokumentuje implementację systemu informatycznego służącego do zdalnej analizy charakterystyki falowania akwenu morskiego. System wykorzystuje techniki Computer Vision oraz metody analizy sygnałów do przetwarzania strumienia wideo z kamer dozorowych. Głównym celem jest bezkontaktowe wyznaczenie parametrów fal (okresu i długości) oraz integracja tych danych z modelem dynamiki jednostki pływającej, co znajduje zastosowanie w systemach bezpieczeństwa żeglugi i monitoringu portowego.

2. Podstawy teoretyczne i metodologia badawcza

Metoda bezkontaktowej identyfikacji parametrów falowania powierzchniowego z wykorzystaniem stacjonarnych kamer dozorowych opiera się na unikalnym powiązaniu hydrodynamiki cieczy z optyką i cyfrowym przetwarzaniem sygnałów. Kluczowym założeniem systemu jest fakt, że procesy dynamiczne zachodzące na powierzchni wody (ruch falowy) modułują strumień świetlny docierający do przetwornika optoelektronicznego (matrycy kamery).

Wybór stałego i odpowiednio sparametryzowanego obszaru zainteresowania (ROI – *Region of Interest*) pozwala na traktowanie zmian średniej luminancji pikseli jako dyskretnego sygnału czasowego, odzwierciedlającego geometryczne i fizyczne fluktuacje profilu fali.

2.1. Hydrodynamiczna zależność dyspersyjna falowania

Opis matematyczny propagacji fal na powierzchni wody opiera się na klasycznej mechanice płynów i teorii fal liniowych Airy’ego. Fala grawitacyjna rozchodząca się po powierzchni swobodnej płynu doskonałego charakteryzuje się relacją wiążącą jej częstotliwość kołową ω , liczbę falową k_w oraz głębokość akwenu h . Ogólna postać równania dyspersyjnego przyjmuje postać:

$$\omega^2 = gk_w \tanh(k_w h) \quad (1)$$

gdzie g oznacza przyspieszenie ziemskie ($9,81 \frac{m}{s^2}$).

Biorąc pod uwagę specyfikę otwartych akwenów morskich lub głębokich kanałów testowych (gdzie spełniony jest warunek wód głębokich: $h > \frac{L}{2}$, funkcja tangensa hiperbolicznego dąży do jedności ($\tanh(k_w h) \rightarrow 1$). Wówczas równanie upraszcza się do postaci:

$$\omega^2 = gk_w \quad (2)$$

Podstawiając standardowe definicje częstotliwości kołowej $\omega = \frac{2\pi}{T}$ (gdzie T to okres fali w sekundach) oraz liczby falowej $k_w = \frac{2\pi}{L}$ (gdzie L to długość fali w metrach), otrzymujemy:

$$\left(\frac{2\pi}{T}\right)^2 = g \left(\frac{2\pi}{L}\right) \rightarrow \frac{4\pi^2}{T^2} = \frac{2\pi g}{L} \quad (3)$$

Ostateczne przekształcenie pozwala na wyznaczenie teoretycznej długości fali dla wód głębokich (L_{deep}):

$$L = \frac{gT^2}{2\pi} \quad (4)$$

W warunkach rzeczywistych pomiarów wizyjnych czysta relacja teoretyczna jest obciążona błędami wynikającymi ze zniekształceń perspektywicznych rzutu ukośnego kamery, załamania światła na granicy ośrodków oraz efektów brzegowych (np. tłumienia fal przy betonowym nabrzeżu portowym). W celu eliminacji tych nieliniowości, w implementacji algorytmicznej systemu wprowadzono empiryczny współczynnik kalibracyjny $k_{cal} = 0,9404$ wyznaczony na drodze walidacji eksperymentalnej. Ostateczne równanie robocze zaimplementowane w kodzie przyjmuje postać:

$$L = \left(\frac{gT^2}{2\pi}\right) \cdot k_{cal} \quad (5)$$

2.2. Cyfrowa analiza widmowa sygnału luminancji (FFT)

Sygnał wejściowy rejestrowany przez kamerę reprezentuje zmiany jasności w dziedzinie czasu $I(t)$. Z powodu zmienności oświetlenia zewnętrznego (np. chwilowe zachmurzenie, refleksy słoneczne), surowy sygnał obarczony jest silną składową stałą oraz trendem niskoczęstotliwościowym (tzw. *DC offset*). Aby transformacja częstotliwościowa odzwierciedlała wyłącznie oscylacje falowe, sygnał poddawany jest próbkowaniu wewnątrz bufora kołowego o skończonej długości N (w kodzie zdefiniowanego jako `max_history_frames`), a następnie centrowaniu wokół wartości średniej μ :

$$x_n = I(n \cdot \Delta t) - \mu, \text{ gdzie } \mu = \frac{1}{N} \sum_{n=0}^{N-1} I(n \cdot \Delta t) \quad (6)$$

Tak przygotowany dyskretny sygnał czasowy x_n transformowany jest do dziedziny częstotliwości przy użyciu Dyskretnej Transformaty Fouriera (DFT):

$$X_k = \sum_{n=0}^{N-1} x_n \cdot e^{\frac{i2\pi kn}{N}}, k = 0, 1, \dots, N-1 \quad (7)$$

W celu optymalizacji obliczeniowej na mikrokomputerze Raspberry Pi 5, algorytm wykorzystuje implementację szybkiej transformaty Fouriera (FFT) z biblioteki `scipy.fft`. Na podstawie wyznaczonego widma amplitudowego $|X_k|$, system odrzuca składowe zwierciślane i analizuje wyłącznie częstotliwości dodatnie w fizycznie uzasadnionym przedziale filtru pasmowoprzepustowego ($0,2 \text{ Hz} < f < 10,0 \text{ Hz}$).

Identyfikacja dominującej częstotliwości falowania (f_{peak}) polega na poszukiwaniu maksimum globalnego funkcji gęstości widmowej:

$$f_{peak} = \operatorname{argmax} |X(f)| \quad (8)$$

Z wyznaczonej częstotliwości szczytowej wprost wynika mierzony okres fali:

$$T = \frac{1}{f_{peak}} \quad (9)$$

Wartość ta przesyłana jest natychmiastowo do modułu hydrodynamicznego w celu obliczenia rzeczywistej długości fali L .

2.3. Estymacja dynamiki powierzchni przy użyciu przepływu optycznego

Podczas gdy analiza FFT wyznacza globalne parametry okresowości fali, badanie lokalnej dynamiki i prędkości nurtu wymaga śledzenia przemieszczeń struktur teksturalnych wody. W tym celu system wykorzystuje dwuetapowe podejście: detekcję punktów kluczowych algorytmem SIFT oraz estymację ich wektorów ruchu metodą przepływu optycznego Lucasa-Kanade.

2.3.1. Wykrywanie cech niezmienniczych skali (SIFT)

Powierzchnia wody jest środowiskiem wysoce dynamicznym i podatnym na zmiany oświetlenia. Zastosowanie klasycznych detektorów krawędzi (np. Canny) lub narożników (np. Harris) okazuje się niewystarczające z powodu braku stabilności cech w kolejnych klatkach obrazu. Algorytm SIFT (*Scale-Invariant Feature Transform*) rozwiązuje ten problem poprzez poszukiwanie punktów referencyjnych w przestrzeni skali przy użyciu różnicy różniczkowej filtrów Gaussa (*DoG – Difference of Gaussians*):

$$D(x, y, \sigma) = L(x, y, k_s \sigma) - L(x, y, \sigma) \quad (10)$$

gdzie $L(x, y, \sigma)$ jest splotem obrazu wejściowego z dwuwymiarową funkcją Gaussa o szerokości σ .

Wykryte ekstrema lokalne są filtrowane pod kątem stabilności i kontrastu. W celu optymalizacji obciążenia procesora CPU Raspberry Pi 5, system wybiera maksymalnie 100

punktów o najwyższym współczynniku odpowiedzi (response), które stanowią precyzyjne markery geometryczne (np. piana fala, lokalne zaburzenia tekstury wody).

2.3.2. Równanie różniczkowe przepływu optycznego Lucasa-Kanade

Mając zadaną macierz punktów początkowych P_0 , system śledzi ich przesunięcie w kolejnej klatce wideo ($t + dt$). Algorytm Lucasa-Kanade bazuje na założeniu stałości jasności (luminancji) śledzonego punktu w czasie:

$$I(x, y, t) = I(x + dx, y + dy, t + dt) \quad (11)$$

Rozwijając powyższe równanie w szereg Taylora i dzieląc przez dt , otrzymujemy fundamentalne równanie przepływu optycznego:

$$\frac{\partial I}{\partial x} u + \frac{\partial I}{\partial y} v + \frac{\partial I}{\partial t} = 0 \rightarrow I_x u + I_y v + I_t = 0 \quad (12)$$

gdzie I_x , I_y to gradienty przestrzenne obrazu, I_t to gradient czasowy, a (u, v) to poszukiwane składowe wektora prędkości pikselowej.

Ponieważ jest to jedno równanie z dwiema niewiadomymi (problem apertury), metoda Lucasa-Kanade wprowadza założenie, że w lokalnym oknie otoczenia Ω o wymiarach 15×15 pikseli (`winSize=(15,15)`), wektor prędkości jest stały. Prowadzi to do nadmiarowego układu równań rozwiązywanego metodą najmniejszych kwadratów:

$$\begin{bmatrix} I_{x1} & I_{y1} \\ I_{x2} & I_{y2} \\ \vdots & \vdots \\ I_{xn} & I_{yn} \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} = - \begin{bmatrix} I_{t1} \\ I_{t2} \\ \vdots \\ I_{tn} \end{bmatrix} \quad (13)$$

Dzięki zastosowaniu piramid obrazu (`maxLevel=3`), algorytm jest w stanie poprawnie estymować zarówno mikropresunięcia tekstury wody, jak i gwałtowne skoki wywołane falami o dużej amplitudzie.

Średnia prędkość nurtu wody w przestrzeni obrazu (v_{px}) obliczana jest jako norma euklidesowa z wektorów przemieszczeń wszystkich poprawnie śledzonych punktów (\$N\$):

$$v_{px} = \frac{1}{N} \sum_{i=1}^N \sqrt{(x_{i,t} - x_{i,t-1})^2 + (y_{i,t} - y_{i,t-1})^2} \cdot FPS \quad (14)$$

W celu eliminacji szumów pomiarowych, wynik surowy jest poddawany ciągłej filtracji dolnoprzepustowej przy użyciu uśredniania wykładniczego:

$$v_{filtrowana} = \beta \cdot v_{px} + (1 - \beta) \cdot v_{poprzednia} \quad (15)$$

gdzie współczynnik tłumienia $\beta = 0,1$ zapewnia idealny kompromis pomiędzy czasem odpowiedzi systemu a stabilnością prezentowanego na ekranie GUI wskaźnika **PREDK. WODY**.

3. Architektura systemu

System został zaimplementowany w języku programowania Python w wersji 3.9 z wykorzystaniem zoptymalizowanych bibliotek OpenCV (`cv2`) oraz SciPy. Architektura oprogramowania opiera się na strukturze modularnej i dzieli się na trzy główne komponenty funkcjonalne:

- **Moduł Akwizycji i Preprocesingu:** Odpowiada za pobieranie klatek wideo ze źródła oraz ich wstępną obróbkę. Przeprowadza konwersję obrazu do odcieni szarości i wykonuje wyrównanie histogramu (`cv2.equalizeHist`) w celu znormalizowania luminancji i wyeliminowania wpływu dynamicznych zmian oświetlenia zewnętrznego na wyniki pomiarów.
- **Moduł Analizy Ruchu (Optical Flow):** Stanowi rdzeń pomiarowy systemu. Wykorzystuje połączone metody SIFT oraz Lucasa-Kanade do ciągłego lokalizowania

i śledzenia przemieszczeń punktów charakterystycznych na powierzchni wody między kolejnymi ramkami wideo.

- **Moduł Fizyki i Sterowania:** Odpowiada za warstwę interaktywną i symulacyjną. Pobiera nastawę manetki użytkownika z poziomu GUI i przetwarza ją przez model inercyjny, który za pomocą cyfrowego filtra dolnoprzepustowego pierwszego rzędu symuluje realną bezwładność jednostki pływającej oraz opory hydrodynamiczne kadłuba.

3.1. Architektura sprzętowa i przepływ danych

System zaprojektowano i uruchomiono jako wbudowaną jednostkę obliczeniową opartą na komputerze jednoukładowym **Raspberry Pi 5 (8GB RAM)**, co zapewnia optymalny balans między wydajnością przetwarzania w czasie rzeczywistym a kompaktowymi wymiarami wymaganymi na autonomicznych pojazdach wodnych.

Bezpośrednim źródłem danych wizyjnych jest dedykowana kamera **Raspberry Pi Camera HD v2** wyposażona w przetwornik o rozdzielczości 8 MPx, połączona z minikomputerem poprzez interfejs taśmowy CSI.

W obecnej fazie implementacji architektura obliczeniowa opiera się w pełni na natywnej mocy procesora głównego Broadcom BCM2712. Mimo fizycznej obecności zewnętrznego akceleratora sztucznej inteligencji **Google Coral USB Accelerator** (Edge TPU) w zestawie laboratoryjnym, moduł ten pozostaje w bieżącej konfiguracji **niewykorzystywany**. Wszystkie procesy systemu: od niskopoziomowej akwizycji i preprocesingu obrazu, przez obróbkę algorytmiczną (analizę SIFT, przepływ optyczny, transformaty FFT), aż po renderowanie graficznego interfejsu użytkownika (GUI) bezpośrednio na macierzach NumPy, realizowane są synchronicznie przez rdzenie CPU. Podejście to pozwoliło na dokładne określenie charakterystyki wydajnościowej procesora w zadaniach wizyjnych, tworząc stabilną metrykę bazową pod przyszłe przeniesienie modeli detekcyjnych na układ Edge TPU.

4. Implementacja algorytmiczna

Implementacja programistyczna systemu została podzielona na sekcje realizujące przetwarzanie potokowe (w czasie rzeczywistym klatka po klatce) wewnątrz głównej pętli programu. Kluczowe operacje numeryczne opierają się na optymalizacjach wektorowych, co zapewnia wysoką wydajność kodu w środowisku jednowątkowym.

4.1. Przetwarzanie sygnału falowania i analiza widmowa

Moduł odpowiedzialny za estymację parametrów falowania monitoruje w sposób ciągły centralny obszar klatki (ROI). W każdej iteracji pętli obliczana jest średnia jasność tego obszaru, która następnie trafia do bufora kołowego `self.brightness_history` o maksymalnej pojemności zdefiniowanej jako `max_history_frames`.

Przed poddaniem sygnału transformacji częstotliwościowej, dane są konwertowane na obiekt biblioteki NumPy. Kluczowym krokiem jest eliminacja składowej stałej (*DC offset*), co zapobiega powstawaniu fałszywego, dominującego piksu dla częstotliwości 0 Hz. Operacja ta polega na odjęciu wartości średniej całego bufora od każdego z jego elementów.

Bezpośrednia implementacja programistyczna tego procesu przebiega następująco:

```
# Konwersja bufora historii jasności na tablicę NumPy
data = np.array(self.brightness_history)

# Centrowanie sygnału - usuwanie składowej stałej (zgodnie z Równaniem 6)
data = data - np.mean(data)

# Wyznaczenie Dyskretnej Transformaty Fouriera (zgodnie z Równaniem 7)
```

```
yf = fft(data)
```

Po wyznaczeniu transformaty `yf`, algorytm oblicza moduł z wartości zespolonych (`np.abs(yf)`), uzyskując widmo amplitudowe sygnału. Program przeszukuje zdefiniowane pasmo częstotliwości (odcinając szumy skrajnie nisko- i wysokoczęstotliwościowe poza zakresem falowania) w poszukiwaniu indeksu o maksymalnej amplitudzie. Na tej podstawie wyznaczana jest częstotliwość szczytowa f_{peak} , a z niej okres fali $T = \frac{1}{f_{peak}}$ oraz długość fali L , która w kodzie aplikuje wspomniany w teorii współczynnik $k = 0.9404$.

4.2. Detekcja punktów SIFT i estymacja prędkości nurtu

Moduł optycznego przepływu bazuje na śledzeniu przesunięć tekstury powierzchni wody. Proces ten realizowany jest w układzie dwufazowym: inicjalizacji (detekcji) oraz śledzenia różniczkowego.

1. **Detekcja i selekcja cech (SIFT):** W przypadku utraty śledzonych punktów lub przy uruchomieniu systemu, obiekt detektora SIFT analizuje monochromatyczną klatkę wideo. Spośród wszystkich wykrytych punktów kluczowych algorytm filtruje i sortuje wyniki, wybierając maksymalnie 100 punktów o najwyższej wartości parametru `response`. Punkty te są konwertowane do macierzy współrzędnych o typie danych `np.float32`, co jest formatem wymaganym przez procedury niskopoziomowe OpenCV.
2. **Śledzenie przemieszczeń (Lucas-Kanade):** Właściwy algorytm optical flow realizowany jest przez funkcję `cv2.calcOpticalFlowPyrLK`. Do funkcji przekazywana jest klatka poprzednia, klatka bieżąca, macierz punktów początkowych oraz zestaw parametrów konfiguracyjnych:
 - o `winSize=(15, 15)` - definiuje rozmiar lokalnego okna całkowania wokół każdego punktu, w obrębie którego wektor prędkości uznaje się za stały.
 - o `maxLevel=3` - określa liczbę poziomów piramidy obrazu, co pozwala na redukcję rozdzielczości i stabilne śledzenie dużych oraz gwałtownych przemieszczeń grzbietów fal.

Funkcja zwraca nową pozycję punktów oraz wektor statusu `st`. Program filtruje wyniki, pozostawiając wyłącznie te punkty, dla których `st == 1` (wskazujący na poprawne znalezienie odpowiednika punktu w nowej klatce).

Dla odfiltrowanej grupy punktów obliczana jest odległość euklidesowa przemieszczenia w pikselach. Średnia wartość tego przesunięcia jest mnożona przez aktualną częstotliwość odświeżania strumienia (FPS), co pozwala wyznaczyć surową prędkość pikselową v_{px} :

$$v_{px} = \frac{1}{N} \sum_{i=1}^N \sqrt{(x_{i,t} - x_{i,t-1})^2 + (y_{i,t} - y_{i,t-1})^2} \cdot FPS \quad (16)$$

W celu uodpornienia wskazań na chwilowe błędy dopasowania punktów lub drgania kamery, surowa wartość v_{px} jest wygładzana za pomocą algorytmu średniej kroczącej z wagą wykładniczą (filtr dolnoprzepustowy pierwszego rzędu):

```
# Wykładnicze wygładzanie prędkości (eliminacja szumu pomiarowego)
system.speed_px_s += 0.1 * (raw_speed - system.speed_px_s)
```

Zastosowanie stałej czasowej opartej na współczynnikach 0.1 oraz 0.9 (odpowiednik $\beta = 0.1$) gwarantuje stabilizację odczytu prędkości wody na ekranie interfejsu GUI, tłumiąc nagłe skoki wartości przy zachowaniu dynamiki zmian prądu morskiego.

4.3. Implementacja interfejsu graficznego (GUI) i modelu inercyjnego łodzi

Graficzny interfejs użytkownika (HUD) został zaprojektowany z myślą o minimalizacji narzutu obliczeniowego. Cały ekran – w tym panele boczne z danymi telemetrycznymi

(**MARINE TERMINAL**), paski postępu, interaktywny suwak manetki oraz osie wykresu widma częstotliwości FFT – jest generowany bezpośrednio poprzez operacje na wielowymiarowych macierzach NumPy, bez użycia zewnętrznych, ciężkich bibliotek okienkowych.

W moduł GUI wbudowano symulator dynamiki wzdłużnej pojazdu, który reaguje na pozycję manetki mocy (*throttle*) zmienianą przez użytkownika za pomocą kliknięć myszy (obsługiwanych przez funkcję zwrotną `cv2.setMouseCallback`). Wartość nastawy manetki (z przedziału 0–100%) stanowi sygnał wejściowy dla modelu fizycznego.

W celu odwzorowania realnego zachowania łodzi elektrycznej na wodzie, prędkość jednostki ($v_{\text{łodzi}}$) wyrażona w węzłach – **kn**) nie zmienia się skokowo, lecz jest obliczana za pomocą dyskretnego równania inercji pierwszego rzędu:

$$v_{\text{łodzi}}(t) = \alpha \cdot v_{\text{target}} + (1 - \alpha) \cdot v_{\text{łodzi}}(t - 1) \quad (17)$$

gdzie v_{target} jest prędkością teoretyczną wynikającą bezpośrednio z wychylenia manetki, a współczynnik bezwładności α odpowiada za płynne narastanie prędkości podczas przyspieszania oraz jej powolny spadek (wybieg jednostki) po odcięciu zasilania.

Wyrenderowana macierz obrazu z nałożonymi elementami analitycznymi i tekstowymi wyświetlana jest w trybie ciągłym za pomocą funkcji `cv2.imshow()`.

5. Interfejs użytkownika, instrukcja obsługi i wizualizacja

Interfejs użytkownika został zaprojektowany w układzie modularnym, tak aby operator mógł jednocześnie obserwować dane surowe, przetworzone oraz aktualny stan symulacji. Całość podzielono na trzy główne sekcje: panel informacyjny, panel sterowania oraz panel wizualizacji.

5.1. Podgląd wideo (prawy panel)

Centralnym elementem prawej części interfejsu jest strumień wideo w czasie rzeczywistym. To właśnie z tego obrazu system wyznacza parametry falowania.

Operator może na bieżąco obserwować:

- zachowanie powierzchni wody,
- kierunek propagacji fal,
- zmiany dynamiki akwenu.

Podgląd jest automatycznie skalowany i wyrównywany do prawej strony ekranu, aby nie zasłaniać paneli informacyjnych.

5.2. Panel informacyjny MARINE TERMINAL (lewa sekcja)

Lewa część interfejsu pełni funkcję panelu diagnostycznego. Wyświetlane są tam najważniejsze parametry hydrodynamiczne:

- **Prędkość wody (px/s)** – wyznaczana na podstawie optycznego przepływu.
- **Częstotliwość fali (Hz)** – dominujący pik widma FFT.
- **Okres fali T (s)** – odwrotność częstotliwości.
- **Długość fali L (m)** – obliczana z równania dyspersji.

Dane są aktualizowane w czasie rzeczywistym, co pozwala operatorowi szybko ocenić warunki hydrometeorologiczne.

Kolorystyka (zieleń, biel i pomarańcz na ciemnym tle) została dobrana tak, aby zapewnić wysoką czytelność nawet przy długotrwałej pracy.

5.3. Manetka mocy – sterowanie łodzią (lewy panel, sekcja środkowa)

Interfejs zawiera pionową manetkę mocy, która umożliwia sterowanie prędkością modelu łodzi.

Obsługa manetki:

- Aby zwiększyć moc – należy **przeciągnąć myszką w górę** w obszarze manetki.
- Aby zmniejszyć moc – przeciągnąć w dół.
- Wskaźnik procentowy pod manetką pokazuje aktualny poziom mocy (0–100%).
- Pozycja suwaka jest aktualizowana w czasie rzeczywistym.

Manetka wpływa na symulowaną prędkość łodzi, która jest dodatkowo wygładzana filtrem wykładniczym, aby uniknąć gwałtownych skoków.

5.4. Panel widma FFT (dolna część interfejsu)

Dolny panel prezentuje **widmo częstotliwościowe falowania**, obliczane na podstawie zmian jasności w centrum obrazu.

Operator może obserwować:


- wysokość słupków odpowiadających amplitudzie sygnału,
- skalę częstotliwości w hercach,
- dominujący pik widma (najsilniejsza częstotliwość fali).

Wizualizacja jest dynamiczna i odświeżana w każdej iteracji pętli głównej.

5.5. Sterowanie klawiaturą

Interfejs obsługuje dwa klawisze funkcyjne:

- **Q** – zamknięcie aplikacji.
- **R** – ponowne wykrycie punktów charakterystycznych (reset SIFT), przydatne gdy śledzenie optyczne straci stabilność.



Zdj. 1. Wygląd interfejsu użytkownika

6. Wnioski i potencjał rozwojowy

Opracowany system wykazuje wysoką skuteczność w estymacji podstawowych parametrów falowania w warunkach stacjonarnych. Wykorzystanie SIFT oraz przepływu optycznego umożliwia pracę w środowisku o zmiennej dynamice.

Kierunki dalszych prac:

- **Automatyczna homografia:** Wprowadzenie automatycznej korekcji perspektywy w celu precyzyjnego mapowania pikseli na metry rzeczywiste na podstawie znanych punktów referencyjnych w porcie.
- **Zaawansowana filtracja:** Zastosowanie filtrów Kalmana w celu lepszej predykcji ruchu jednostki pływającej przy gwałtownych zmianach pogody.
- **Integracja AI:** Zastąpienie klasycznego SIFT sieciami neuronowymi typu *deep learning* do detekcji cech na powierzchni wody, co zwiększyłoby odporność systemu na nocne warunki oświetleniowe.

7. Literatura

1. Zhou Z, Liu J, Liu C, Lu W, Guo A. Wave parameters identification based on surveillance cameras. *Measurement* vol. 245 <https://doi.org/10.1016/j.measurement.2024.116581> (2025).